

Perceptron ciągły i dyskretny

Jacek Kluska

Politechnika Rzeszowska

Klasyfikator ciągły

Perceptron z ciągłą funkcją aktywacji - wejścia (x_1, \dots, x_N) , wyjście y

$$y = f(n); \quad n = \langle \mathbf{w}, \mathbf{x} \rangle + b = w_1 x_1 + \dots + w_N x_N + b$$

f - różniczkowalna, np.

Znany jest zbiór par uczących $\{(\mathbf{x}_1, d_1), (\mathbf{x}_2, d_2), \dots, (\mathbf{x}_Q, d_Q)\}$.

- $y = f(n) = \frac{2}{1 + e^{-\lambda n}} - 1, \quad \lambda > 0, y \in (-1, 1)$ - bipolarna
- $y = f(n) = \frac{1}{1 + e^{-\lambda n}}, \quad \lambda > 0, y \in (0, 1)$ - unipolarna

Dane: Zbiór par uczących $\{(\mathbf{x}_1, d_1), (\mathbf{x}_2, d_2), \dots, (\mathbf{x}_Q, d_Q)\}$, gdzie $d_i \in \{-1, 1\}$ lub $d_i \in \{0, 1\}$.

Błąd

$$E(k) = \frac{1}{2} [d(k) - y(k)]^2, \quad k = 0, 1, 2, \dots$$

Problem

Znaleźć taki algorytm uczenia \underline{w} i b , aby

$$E(k) \longrightarrow \min, \quad \forall k$$

- Gradienty

$$\nabla_{\mathbf{w}} E = \frac{\partial E}{\partial y} \frac{\partial y}{\partial n} \nabla_{\mathbf{w}} n = \frac{\partial E}{\partial y} \frac{\partial y}{\partial n} \begin{bmatrix} \frac{\partial n}{\partial w_1} \\ \vdots \\ \frac{\partial n}{\partial w_N} \end{bmatrix}$$
$$\nabla_b E = \frac{\partial E}{\partial y} \frac{\partial y}{\partial n} \frac{\partial n}{\partial b}$$

Algorytm uczenia perceptronu - metoda "delta"

$$\begin{aligned}\mathbf{w}(k+1) &= \mathbf{w}(k) - \eta \nabla_{\mathbf{w}} E \\ b(k+1) &= b(k) - \eta \nabla_b E, \quad \eta > 0\end{aligned}$$

- f - bipolarna

$$\frac{\partial f}{\partial n} = \frac{\partial}{\partial n} \left(\frac{2}{1 + e^{-\lambda n}} - 1 \right) = \frac{\lambda}{2} (1 - y^2)$$

- f - unipolarna

$$\frac{\partial f}{\partial n} = \frac{\partial}{\partial n} \left(\frac{1}{1 + e^{-\lambda n}} \right) = \lambda y (1 - y)$$

Algorytm uczenia perceptronu dla funkcji bipolarnej i unipolarnej

Algorytm uczenia perceptronu dla funkcji bipolarnej

$$\mathbf{w}(k+1) = \mathbf{w}(k) + \eta \frac{\lambda}{2} [d(k) - y(k)] [1 - y^2(k)] \mathbf{x}(k)$$
$$b(k+1) = b(k) + \eta \frac{\lambda}{2} [d(k) - y(k)] [1 - y^2(k)]$$

Algorytm uczenia perceptronu dla funkcji unipolarnej

$$\mathbf{w}(k+1) = \mathbf{w}(k) + \eta \lambda [d(k) - y(k)] y(k) [1 - y(k)] \mathbf{x}(k)$$
$$b(k+1) = b(k) + \eta \lambda [d(k) - y(k)] y(k) [1 - y(k)]$$

Uwaga: Uczenie klasyfikatora ciągłego nawet dla problemów liniowo separowalnych nie zawsze prowadzi do poprawnej klasyfikacji (Wittner, Denker, 1988).

Perceptron ze skokową funkcją aktywacji - wejścia (x_1, \dots, x_N) ,
wyjście y

$$y = f(n); \quad n = \langle \mathbf{w}, \mathbf{x} \rangle + b = w_1 x_1 + \dots + w_N x_N + b$$

Funkcja aktywacji

$$y = f(n) = \text{sign}(n) = \begin{cases} 1 & \Leftrightarrow n \geq 0 \\ -1 & \Leftrightarrow n < 0 \end{cases}$$

Dane: Zbiór par uczących $\{(\mathbf{x}_1, d_1), (\mathbf{x}_2, d_2), \dots, (\mathbf{x}_Q, d_Q)\}$, gdzie $d_i \in \{-1, 1\}$ lub $d_i \in \{0, 1\}$.

Błąd

$$E(k) = \frac{1}{2} [d(k) - y(k)]^2, \quad k = 0, 1, 2, \dots$$

Problem

Znaleźć taki algorytm uczenia \underline{w} i b , aby

$$E(k) = 0, \quad \forall k \geq k_0$$

Algorytm uczenia perceptronu dyskretnego

$$\mathbf{w}(k+1) = \mathbf{w}(k) + \frac{1}{2}c[d(k) - y(k)]\mathbf{x}(k)$$

$$b(k+1) = b(k) + \frac{1}{2}c[d(k) - y(k)]$$

Wskazówka: współczynnik korekcji

$$c(k) = c_0 \frac{|\langle \mathbf{w}(k), \mathbf{x}(k) \rangle|}{\|\mathbf{x}(k)\|^2}, \quad c_0 > 0$$

Uwaga: Uczenie klasyfikatora dyskretnego według wzoru jak wyżej, dla problemów liniowo separowalnych - zawsze prowadzi do poprawnej klasyfikacji w skończonej liczbie kroków.

Dowód zbieżności reguły uczenia klasyfikatora dyskretnego

- Funkcja aktywacji każdego neuronu jest typu "signum": $y \in \{-1, 1\}$.
- Mamy 2 klasy punktów: K_1 i K_2 .

$$\mathbf{x} \in K_1 \Leftrightarrow \langle \mathbf{w}, \mathbf{x} \rangle \leq 0 \Leftrightarrow \text{sign } \langle \mathbf{w}, \mathbf{x} \rangle = -1$$

$$\mathbf{x} \in K_2 \Leftrightarrow \langle \mathbf{w}, \mathbf{x} \rangle > 0 \Leftrightarrow \text{sign } \langle \mathbf{w}, \mathbf{x} \rangle = +1$$

- Fakt:

$$\mathbf{x} \in K_2 \Rightarrow (-\mathbf{x}) \in K_1$$

ponieważ $\langle \mathbf{w}, \mathbf{x} \rangle > 0 \Rightarrow \langle \mathbf{w}, (-\mathbf{x}) \rangle < 0$

- **Modyfikujemy ciąg uczący:** eliminujemy te \mathbf{x} , które nie powodują zmiany wag. Jeżeli $\mathbf{x} \in K_1$ i $[d(k) - y(k)] = [1 - (-1)] = 2$. Wtedy $\mathbf{w}(k+1) = \mathbf{w}(k) + c\mathbf{x}(k)$, $c > 0$. Nie będziemy podawać w trakcie uczenia punktów $\mathbf{x} \in K_2$, lecz $(-\mathbf{x}) \in K_1$. Zatem $\mathbf{w}(k+1) = \mathbf{w}(k) + c\mathbf{x}(k)$. **Zmodyfikowany ciąg uczący:**

$$K'_1 = K_1 \cup \{(-\mathbf{x}) : \mathbf{x} \in K_2\}$$

Dowód zbieżności reguły uczenia klasyfikatora dyskretnego

- założenia i fakty

Założenia:

- 1 Problem jest liniowo separowalny:

$$\exists \mathbf{w}^* = \mathbf{w}^{opt} : \quad \langle \mathbf{w}^*, \mathbf{x} \rangle > 0, \quad \forall \mathbf{x}$$

- 2 Bez utraty ogólności: $\mathbf{w}(1) = \mathbf{0}$.

Fakt 1

- wynika z modyfikacji ciągu uczącego i stąd, że $\mathbf{w}(1) = \mathbf{0}$:

$$\mathbf{w}(k+1) = \mathbf{w}(k) + c\mathbf{x}(k), \quad \forall \mathbf{x} \in K'_1$$

$$\Downarrow$$

$$\mathbf{w}(k+1) = c\mathbf{x}(1) + c\mathbf{x}(2) + \dots + c\mathbf{x}(k)$$

Dowód zbieżności reguły uczenia klasyfikatora dyskretnego

- fakty

Fakt 2

- wynika z liniowej separowalności:

$$\exists \delta : \quad \inf_{\mathbf{x}} \langle \mathbf{w}^*, \mathbf{x} \rangle = \delta > 0$$

Rozpatrzmy $\langle \mathbf{w}^*, \mathbf{w}(k+1) \rangle$:

$$\begin{aligned} \|\mathbf{w}^*\| \|\mathbf{w}(k+1)\| &\geq \langle \mathbf{w}^*, \mathbf{w}(k+1) \rangle \\ &= \langle \mathbf{w}^*, c\mathbf{x}(1) \rangle + \langle \mathbf{w}^*, c\mathbf{x}(2) \rangle + \dots + \langle \mathbf{w}^*, c\mathbf{x}(k) \rangle \\ &\geq ck\delta \end{aligned}$$

$$\|\mathbf{w}(k+1)\|^2 \geq \frac{c^2 k^2 \delta^2}{\|\mathbf{w}^*\|^2}$$

Dowód zbieżności reguły uczenia klasyfikatora dyskretnego - fakty, c.d.

Z drugiej strony:

$$\begin{aligned}\|\mathbf{w}(k+1)\|^2 &= \langle \mathbf{w}(k) + c\mathbf{x}(k), \mathbf{w}(k) + c\mathbf{x}(k) \rangle \\ &= \|\mathbf{w}(k)\|^2 + 2c \langle \mathbf{w}(k), \mathbf{x}(k) \rangle + c^2 \|\mathbf{x}(k)\|^2\end{aligned}$$

Korekcja wag następuje dopóty, dopóki $\langle \mathbf{w}(k), \mathbf{x}(k) \rangle \leq 0$, więc

$$\begin{aligned}\|\mathbf{w}(k+1)\|^2 &\leq \|\mathbf{w}(k)\|^2 + c^2 \|\mathbf{x}(k)\|^2 \\ &\leq \|\mathbf{w}(k)\|^2 + c^2 M^2 \leq kc^2 M^2\end{aligned}$$

gdzie $M = \sup_{\mathbf{x}} \|\mathbf{x}\|$. Czyli

$$kc^2 M^2 \geq \|\mathbf{w}(k+1)\|^2 \geq \frac{c^2 k^2 \delta^2}{\|\mathbf{w}^*\|^2} \Rightarrow k \leq \left(\frac{M \|\mathbf{w}^*\|}{\delta} \right)^2.$$