


Uczący się system ekspertowy Takagi-Sugeno


Jacek Kluska
Politechnika Rzeszowska

Uczący się SE-TS



Zał.: Funkcje przynależności są różniczkowalne, np.

$$\mu(x; m, \sigma) = \exp\left(- (x - m)^2 / \sigma^2\right)$$



Znany jest zbiór par uczących $\{(\underline{x}_1, d_1), (\underline{x}_2, d_2), \dots, (\underline{x}_Q, d_Q)\}$.

1. Zbiory rozmyte wejściowe:

$$x_1: \mu_{11}(x_1; m_{11}, \sigma_{11}), \dots, \mu_{1,J_1}(x_1; m_{1,J_1}, \sigma_{1,J_1}),$$

$$\vdots$$

$$x_L: \mu_{L,1}(x_L; m_{L,1}, \sigma_{L,1}), \dots, \mu_{L,J_L}(x_L; m_{L,J_L}, \sigma_{L,J_L}),$$

$$\mu_{ij}(x_i; m_{ij}, \sigma_{ij}), \quad x_i \leftrightarrow i \in \{1, \dots, L\}, \quad j - \text{nr zbioru}, \quad j \in \{1, \dots, J_i\}$$

2. N - reguł

$$\mu_{1,j_a}(x_1; m_{1,j_a}, \sigma_{1,j_a}) \times \dots \times \mu_{L,j_b}(x_L; m_{L,j_b}, \sigma_{L,j_b}) * \rightarrow u_1$$

$$\vdots$$

$$\mu_{1,j_c}(x_1; m_{1,j_c}, \sigma_{1,j_c}) \times \dots \times \mu_{L,j_d}(x_L; m_{L,j_d}, \sigma_{L,j_d}) * \rightarrow u_n, \quad \boxed{u_n \in R}$$

$$\vdots$$

$$\mu_{1,j_e}(x_1; m_{1,j_e}, \sigma_{1,j_e}) \times \dots \times \mu_{L,j_g}(x_L; m_{L,j_g}, \sigma_{L,j_g}) * \rightarrow u_N$$

Parametry do uczenia

$$W = \{m_{11}, \dots, m_{L,J_L}, \sigma_{11}, \dots, \sigma_{L,J_L}, u_1, \dots, u_N\},$$

$$\text{card}(W) = 2(J_1 + \dots + J_L) + N$$

Postawienie problemu i idea rozwiązania

Dla zadanej struktury SE i znanym zbiorze par uczących $\{(\underline{x}_1, d_1), (\underline{x}_2, d_2), \dots, (\underline{x}_Q, d_Q)\}$, znaleźć algorytm uczenia, aby

$$E(k) = \frac{1}{2} [u(k) - d(k)]^2 \rightarrow \min, \quad \forall k = 1, 2, \dots$$

Idea rozwiązania:

Zaprojektować rozmyto-neuronowy system ekspertowy T-S:

$$u = \frac{\sum_{n=1}^N P_n \left(\mu_{11}, \dots, \mu_{L, J_L} \right) \cdot u_n}{\sum_{n=1}^N P_n \left(\mu_{11}, \dots, \mu_{L, J_L} \right)}$$

uczony metodą spadku gradientu.

$$w(k+1) = w(k) - \eta \frac{\partial E}{\partial w}, \quad \eta > 0.$$

$$w \in W = \{m_{11}, \dots, m_{L,J_L}, \sigma_{11}, \dots, \sigma_{L,J_L}, u_1, \dots, u_N\}$$

Algorytm ogólny:

$$m_{ij}(k+1) = m_{ij}(k) - \eta_m \frac{\partial E}{\partial m_{ij}}, \quad \eta_m > 0$$

$$\sigma_{ij}(k+1) = \sigma_{ij}(k) - \eta_\sigma \frac{\partial E}{\partial \sigma_{ij}}, \quad \eta_\sigma > 0$$

$$u_n(k+1) = u_n(k) - \eta_u \frac{\partial E}{\partial u_n}, \quad \eta_u > 0$$

Problem cząstkowy:

$$\frac{\partial E}{\partial m_{ij}} = ?, \quad \frac{\partial E}{\partial \sigma_{ij}} = ?, \quad \frac{\partial E}{\partial u_n} = ?$$

Obliczenie pierwszego składnika

Niech: Q_{ij} - zbiór indeksów tych reguł, których poprzedniki P_n zawierają μ_{ij} .

$$\frac{\partial E}{\partial m_{ij}} = \frac{\partial E}{\partial u} \frac{\partial u}{\partial m_{ij}} = (u - d) \frac{\partial u}{\partial m_{ij}}$$

$$\frac{\partial u}{\partial m_{ij}} = \sum_{q \in Q_{ij}} \left[\frac{\partial}{\partial P_q} \left(\frac{\sum_{q \in Q_{ij}} P_q u_q + \sum_{r \notin Q_{ij}} P_r u_r}{\sum_{q \in Q_{ij}} P_q + \sum_{r \notin Q_{ij}} P_r} \right) \frac{\partial P_q}{\partial \mu_{ij}} \frac{\partial \mu_{ij}}{\partial m_{ij}} \right]$$

Obliczenie pierwszego składnika - c.d.

$$\begin{aligned}\frac{\partial u}{\partial m_{ij}} &= \sum_{q \in Q_{ij}} \left[\left(\frac{u_q Mian - Licz \cdot 1}{Mian^2} \right) \frac{\partial P_q}{\partial \mu_{ij}} \frac{\partial \mu_{ij}}{\partial m_{ij}} \right] \\ &= \frac{1}{Mian} \frac{\partial \mu_{ij}}{\partial m_{ij}} \sum_{q \in Q_{ij}} \left[(u_q - u) \frac{\partial P_q}{\partial \mu_{ij}} \right]\end{aligned}$$

$$\frac{\partial P_q}{\partial \mu_{ij}} = \frac{\partial}{\partial \mu_{ij}} (\mu_{1,j_1} \cdot \dots \cdot \mu_{ij} \cdot \dots \cdot \mu_{1,j_1}) = \frac{P_q}{\mu_{ij}}$$

$$\frac{\partial \mu_{ij}}{\partial m_{ij}} = 2 \frac{x_i - m_{ij}}{\sigma_{ij}^2} \mu_{ij}$$

$$\boxed{\frac{\partial E}{\partial m_{ij}} = \frac{2(u - d)}{\sum_n P_n} \frac{x_i - m_{ij}}{\sigma_{ij}^2} \sum_{q \in Q_{ij}} (u_q - u) P_q}$$

Obliczenie drugiego składnika

Q_{ij} - zbiór indeksów tych reguł, których poprzedniki P_n zawierają μ_{ij} .

$$\frac{\partial E}{\partial \sigma_{ij}} = \frac{\partial E}{\partial u} \frac{\partial u}{\partial \sigma_{ij}} = (u - d) \frac{\partial u}{\partial \sigma_{ij}}$$

$$\frac{\partial u}{\partial \sigma_{ij}} = \sum_{q \in Q_{ij}} \left[\frac{\partial}{\partial P_q} \left(\frac{\sum_{q \in Q_{ij}} P_q u_q + \sum_{r \notin Q_{ij}} P_r u_r}{\sum_{q \in Q_{ij}} P_q + \sum_{r \notin Q_{ij}} P_r} \right) \frac{\partial P_q}{\partial \mu_{ij}} \frac{\partial \mu_{ij}}{\partial \sigma_{ij}} \right]$$

Obliczenie drugiego składnika - c.d.

$$\begin{aligned}\frac{\partial u}{\partial \sigma_{ij}} &= \sum_{q \in Q_{ij}} \left[\left(\frac{u_q Mian - Licz \cdot 1}{Mian^2} \right) \frac{\partial P_q}{\partial \mu_{ij}} \frac{\partial \mu_{ij}}{\partial \sigma_{ij}} \right] \\ &= \frac{1}{Mian} \frac{\partial \mu_{ij}}{\partial \sigma_{ij}} \sum_{q \in Q_{ij}} \left[(u_q - u) \frac{\partial P_q}{\partial \mu_{ij}} \right]\end{aligned}$$

$$\frac{\partial P_q}{\partial \mu_{ij}} = \frac{\partial}{\partial \mu_{ij}} (\mu_{1,j_1} \cdot \dots \cdot \mu_{ij} \cdot \dots \cdot \mu_{1,j_1}) = \frac{P_q}{\mu_{ij}}$$

$$\frac{\partial \mu_{ij}}{\partial \sigma_{ij}} = 2 \frac{(x_i - m_{ij})^2}{\sigma_{ij}^3} \mu_{ij}$$

$$\frac{\partial E}{\partial \sigma_{ij}} = \frac{2(u - d)}{\sum_n P_n} \frac{(x_i - m_{ij})^2}{\sigma_{ij}^3} \sum_{q \in Q_{ij}} (u_q - u) P_q$$

Obliczenie trzeciego składnika

$$\begin{aligned}\frac{\partial E}{\partial u_n} &= \frac{\partial E}{\partial u} \frac{\partial u}{\partial u_n} \\ &= (u - d) \frac{\partial}{\partial u_n} \left(\frac{\sum_{n=1}^N P_n u_n}{\sum_{n=1}^N P_n} \right) \\ &= (u - d) \frac{P_n}{\sum_{n=1}^N P_n}\end{aligned}$$

Procedura numeryczna uczenia systemu ekspertowego

$$\forall i \in \{1, \dots, L\}, \forall j \in \{1, \dots, J_L\}, \forall n \in \{1, \dots, N\}$$

Algorytm zmiany parametru m_{ij} :

$$\Delta m_{ij}(k) = 2\eta_m \frac{d(k) - u(k)}{\sum_{n=1}^N P_n(k)} \frac{x_i(k) - m_{ij}(k)}{\sigma_{ij}^2(k)} \sum_{q \in Q_{ij}} P_q(k) [u_q(k) - u(k)]$$

$$m_{ij}(k+1) = m_{ij}(k) + \Delta m_{ij}(k)$$

Algorytm zmiany σ_{ij} :

$$\Delta \sigma_{ij}(k) = 2\eta_\sigma \frac{d(k) - u(k)}{\sum_{n=1}^N P_n(k)} \frac{[x_i(k) - m_{ij}(k)]^2}{\sigma_{ij}^3(k)} \sum_{q \in Q_{ij}} P_q(k) [u_q(k) - u(k)]$$

$$\sigma_{ij}(k+1) = \sigma_{ij}(k) + \Delta \sigma_{ij}(k)$$

Algorytm zmiany u_n :

$$u_n(k+1) = u_n(k) + \eta_u [d(k) - u(k)] \frac{P_n(k)}{\sum_{n=1}^N P_n(k)}$$

Przykład: Dwuwęściowy SE-TS

- Zbiory rozmyte wejściowe:

$$x_1 : \mu_{11}(x_1, m_{11}, \sigma_{11}), \mu_{12}(x_1, m_{12}, \sigma_{12}), \mu_{13}(x_1, m_{13}, \sigma_{13}),$$

$$x_2 : \mu_{21}(x_2, m_{21}, \sigma_{21}), \mu_{22}(x_2, m_{22}, \sigma_{22}), \mu_{23}(x_2, m_{23}, \sigma_{23}),$$

- Format reguł:

$$(\mu_{11} \times \mu_{21}) * \rightarrow u_1 \Leftrightarrow P_1(x_1 \times x_2) * \rightarrow u_1$$

$$(\mu_{11} \times \mu_{22}) * \rightarrow u_2 \Leftrightarrow P_2(x_1 \times x_2) * \rightarrow u_2$$

\vdots

$$(\mu_{13} \times \mu_{23}) * \rightarrow u_9 \Leftrightarrow P_9(x_1 \times x_2) * \rightarrow u_9$$


Przykład: Dwuwęściowy SE-TS - dane startowe

- Dane startowe: zbiory rozmyte dla x_1

$$\mu_{11} = \exp\left(- (x_1 + 4)^2 / 1\right),$$

$$\mu_{12} = \exp\left(- (x_1 - 1)^2 / 8\right),$$

$$\mu_{13} = \exp\left(- (x_1 - 2)^2 / 5\right)$$




Przykład: Dwuwęściowy SE-TS - dane startowe - c.d.

- Dane startowe: zbiory rozmyte dla x_2

$$\mu_{21} = \exp \left(- (x_2 + 2)^2 / 2 \right),$$


$$\mu_{22} = \exp \left(- (x_2 + 0.5)^2 / 6 \right),$$

$$\mu_{23} = \exp \left(- (x_2 - 3)^2 / 4 \right)$$




Przykład: Dwuwęściowy SE-TS - wizualizacja reguł

- $R_1 = \mu_{11} * \mu_{21} * (1)$




- $R_2 = \mu_{11} * \mu_{22} * (2)$



Przykład: Dwuwęściowy SE-TS - na czym polega uczenie

- $J_1 = 3, J_2 = 3, N = J_1 J_2 = 9,$
- Liczba parametrów do uczenia: $2(J_1 + J_2) + N = 21$



Przed uczeniem

Po uczeniu

Przykład: Wahadło odwrócone na wózku

$$\frac{dx_1}{dt} = x_2$$

$$\frac{dx_2}{dt} = \frac{(p_2 \sin x_1 - p_3 x_2) p_1 - \left(x_2^2 \sin x_1 - p_5 x_4 + \frac{k}{ml} u \right) \cos x_1}{p_1 p_4 - \cos^2 x_1}$$

$$\frac{dx_3}{dt} = x_4$$

$$\frac{dx_4}{dt} = \frac{\left(x_2^2 \sin x_1 - p_5 x_4 + \frac{k}{ml} u \right) p_4 - (p_2 \sin x_1 - p_3 x_2) \cos x_1}{p_1 p_4 - \cos^2 x_1}$$

Przykład: Wahadło odwrócone na wózku - dane

x_1 - kąt odchylenia pręta, x_3 - odchylenie wózka (droga),

u - przyśpieszenie = **sterowanie**, ($k = 0.96$ - dla uproszczenia)

$$p_1 = 1 + \frac{m_c}{m} = 36.0, \quad m_c = 0.14 \text{ -m. wózka}, \quad m = 0.004 \text{ -m. pręta } [kg]$$

$$p_2 = \frac{g}{l} = 32.7, \quad g = 9.81 \text{ } [m/s^2] \text{ -przyśp. ziem.}, \quad 2l = 0.6 \text{ } [m] \text{ -dł. pręta}$$

$$p_3 = \frac{c_1}{ml^2} = 27.0, \quad c_1 = 0.00972 \text{ } [kg \cdot m^2/s] \text{ -wsp. tłum. r. obr. pręta}$$

$$p_4 = 1 + \frac{J}{ml^2} = \frac{4}{3} \quad J \text{ -mom. bezwł. pręta}, \quad J = \frac{ml^2}{3}$$

$$p_5 = \frac{c_2}{ml^2} = 5.0 \quad c_2 \text{ -wsp. tłum. r. wózka}, \quad c_2 = 0.0018 \text{ } [kg/s]$$

Przykład: Wahadło odwrócone na wózku - przypadek dwuwymiarowy

$$\frac{dx_1}{dt} = x_2$$


$$\frac{dx_2}{dt} = \frac{(p_2 \sin x_1 - p_3 x_2) p_1 - x_2^2 \sin x_1 \cos x_1 - \frac{k \cos x_1}{ml} u}{p_1 p_4 - \cos^2 x_1}$$

Czy istnieje SE-TS generujący taki ciąg sterowania, dla którego ruch wahadła zanika bez oscylacji i z zadaną szybkością?

Tak. (Jest na to dowód formalny)

Przykład: Wahadło odwrócone na wózku - powierzchnia sterująca


Rezultat uczenia SE-TS



$$u = g(x_1, x_2)$$

Przykład: Wahadło odwrócone na wózku - typowe przebiegi


Rezultat uczenia SE-TS



$$x_1(0) = 0.2\pi, \quad x_2(0) = 0.2$$

Przykład: Wahadło odwrócone na wózku - portret fazowy

Rezultat uczenia SE-TS



$$(x_1(t), x_2(t)), t \in (0, 10).$$